Московский авиационный институт

(национальный исследовательский университет)

Институт информационные технологии и прикладной математики

Кафедра вычислительной математики и программирования

Лабораторная работа №1 по курсу «Информационный поиск»

Студент: Е.М. Стифеев
Преподаватель: А.А. Кухтичев
Группа: М8О-109М-21
Дата: 11.10.21
Оценка:
Подпись:

Москва, 2021

Лабораторная работа №1 «Добыча корпуса документов»

Необходимо подготовить корпус документов, который будет использован при выполнении остальных лабораторных работ:

- Скачать его к себе на компьютер. В отчёте нужно указать источник данных.
- Ознакомиться с ним, изучить его характеристики. Из чего состоит текст? Есть ли дополнительная мета-информация? Если разметка текста, какая она?
- Разбить на документы.
- Выделить текст.
- Найти существующие поисковики, которые уже можно использовать для поиска по
- выбранному набору документов (встроенный поиск Википедии, поиск *Google* с использованием ограничений на *URL* или на сайт). Если такого поиска найти невозможно, то использовать корпус для выполнения лабораторных работ нельзя!
- Привести несколько примеров запросов к существующим поисковикам, указать недостатки в полученной поисковой выдаче.

В результатах работы должна быть указаны статистическая информация о корпусе:

- Размер «сырых» данных.
- Количество документов.
- Размер текста, выделенного из «сырых» данных.
- Средний размер документа, средний объём текста в документе.

1. Описание

Для выполнения поставленной задачи требуется написать веб-скрапер. После длительных размышлений над тематикой документов было принято решение «обкачать» сайты с кинотематикой. И, конечно же, в качестве первого кандидата был выбран крупнейший сборник подобных документов ру-сегмента интернета *kinopoisk* (https://www.kinopoisk.ru/).

Рассмотрим структуру страницы о фильме на примере https://www.kinopoisk.ru/film/64021/ (х/ф «Зомби по имени Шон»). Открыв её в браузере, наблюдаем следующую интересующую нас информацию для скрапинга:

- Название фильма («Зомби по имени Шон»);
- Альтернативное название («Shaun of the Dead»);
- Год производства (2004);
- Средняя оценка пользователей (7.4);
- Страна/страны производства фильма (Великобритания, Франция);
- Режиссёр/режиссёры (Эдгар Райт);
- Сценарист/сценаристы (Саймон Пегг, Эдгар Райт);
- Актёры (Саймон Пегг, Ник Фрост, ...);
- Жанры (ужасы, комедия);
- Описание («В жизни Шона все идет наперекосяк ...»);
- Рецензии («Пересматриваю эту пародию ритуально ...»).

Теперь нужно каким-то образом найти ссылки на все фильмы из базы. Для этого была найдена карта сайта https://www.kinopoisk.ru/sitemaps/sitemap.xml (ссылка на неё указана в https://www.kinopoisk.ru/robots.txt), откуда был извлечён список ссылок на все фильмы, хранящиеся на сайте. Получив такой список, можно «распарсить» каждую ссылку, выделив нужные сведения из html-кода, совмещая такие техники как:

- Получение кода *html*-кода страницы (*Scrapy*, *Selenium*)
- Исследование кода страницы через встроенный в браузер (в моём случае *Yandex Browser*) инспектор сайта, который помогает понять, какой блок *html*-кода, за какой элемент страницы отвечает.
- Средства анализа древовидной структуры страницы (*BeautifulSoup*) с целью извлечения нужных тэгов.
- Сохранение информации в локальный файл (в моём случае *jsonlines*).

В процессе выполнения работы автор столкнулся с такими проблемами, как:

- Динамически подгружающая секциями с отзывами.

Сначала был написан скрипт, использующий фреймворк *Selenium* для выполнения *java script*'а на странице, работающий по принципу: загрузить страницу, проскроллить в её конец, подождать пока на странице на появится нужный блок с отзывами (по появлению определённого тэга) и тогда извлечь отзывы из блока, либо пока не пройдёт, например, 5 секунд, и тогда завершить обработку страницы без отзывов.

Затем автор выяснил по карте сайта, что есть ссылки на страницы, на которых находятся только отзывы https://www.kinopoisk.ru/film/64021/reviews/ (64021 – уникальный номер фильма). В связи с чем было принять решение обрабатывать по две страницы на фильм (фильм + отзывы) с секундной задержкой.

- Капча.

При её появлении было принято решение пропускать обработку таких страниц, занося ссылку в отдельный файл с целью ручного распознавания в будущем (таких страниц было 1% от всех). Также можно воспользоваться таким инструментом как *tesseract* [1] для автоматической обработки (это также требует ручной обработки определённого количества изображений).

Дополнительно была обкачана новостная лента https://www.kinopoisk.ru/media/, торрент-трекер http://filmplace.ru/ и портал по японской мультипликации https://shikimori.one/.

2. Исходный код

Структура проекта

- film_scraper
  - film_scraper
    - captcha (файлы со ссылками на страницы с капчей)
      - sitemap_captcha_links1.txt
      - sitemap_captcha_links2.txt
    - jsons (выходные файлы)
      - films1.jsonlines
      - films2.jsonlines
    - sitemaps (файлы со ссылками для обработки пауком)
      - sitemap_film_review1.txt
      - sitemap_film_review2.txt
      - sitemap_film1.txt
      - …
      - sitemap_film18.txt
    - spiders (пауки)
      - __init__.py
      - FSpyder.py
    - __init__.py
    - items.py
    - middlewares.py
    - pipelines.py
    - setting.py (глобальные настройки)
  - scrapy.cfg

Запуск

Итоговый «паук», скачанный с https://github.com/Stifeev/Information-retrieval/tree/main/ЛР1, требует настройки абсолютного пути до рабочей папки в файле ./film_scraper/film_scraper/settings.py:

```
# Crawl responsibly by identifying yourself (and your website) on the user-agent
USER_AGENT = "film_scraper"

# Obey robots.txt rules
ROBOTSTXT_OBEY = True

# Global variables
NUM_SITEMAP = 1             # номер карты с ссылками

PATH_2_WORK_DIR = "path_2_film_scraper/film_scraper"

PATH_2_JSONS = path.join(PATH_2_WORK_DIR, "film_scraper/jsons")
PATH_2_FILMS_JSON =  path.join(PATH_2_JSONS, "films{:d}.jsonlines".format(NUM_SITEMAP))
PATH_2_ARTICLES_JSON =  path.join(PATH_2_JSONS, "content{:d}.jsonlines".format(NUM_SITEMAP))

PATH_2_SITEMAPS = path.join(PATH_2_WORK_DIR, "film_scraper/sitemaps")
PATH_2_SITEMAP = path.join(PATH_2_SITEMAPS, "sitemap_film_review{:d}.txt".format(NUM_SITEMAP))

PATH_2_CAPTCHAS = path.join(PATH_2_WORK_DIR, "film_scraper/captcha")
PATH_2_CAPTCHA = path.join(PATH_2_CAPTCHAS, "sitemap_captcha_links{:d}.txt".format(NUM_SITEMAP))
PATH_2_DRIVER = path.join(PATH_2_WORK_DIR, "chromedriver.exe")
```

Запуск осуществляется командой ниже из директории ./film_scraper/film_scraper/spiders:

```
$ scrapy runspider FSpider.py
```

Структура FSpyder.py

Сигнатура	Описание
`def extract_key(url)`	Извлечь уникальный номер фильма из ссылки на него
`def find_wrap(search)`	Безопасный механизм обработки поиска в *html*-коде (возврат пустой строки, если поиск неудачный)
`def fetch_headers(page, item)`	Извлечь основную информацию из страницы (всё, кроме отзывов) в объект *item*
`def fetch_reviews(spider, item, url, review_count)`	Извлечь отзывы в объект *item*. Функция умеет обрабатывать случаи, когда фильм имеет больше отзывов, чем *REVIEWS_OFFSET* (200 по умолчанию) через обработку нескольких страниц
`class FSpider(Spider)`	Класс паука
`def __init__(self, *args, **kwargs)`	-Извлечение ключей всех записей из текущего *json*-файла в множество

	(*set*) *film_ids* для предотвращения добавление неуникальных записей; -Извлечение списка ссылок на фильмы для обработки из файла и сравнение их с ключами; -Очистка файла с ссылками на страницы с капчей; -Инициализация веб-драйвера
`def parse(self, response)`	Основная функция обработки страницы. Извлечение *item*'а.
`def closed(self, reason)`	Обработка остановки паука

3. Выводы

На данный момент удалось обработать несколько сайтов: www.kinopoisk.ru, filmplace.ru и shikimori.one.

Сырые данные	
Общее число обработанных страниц:	≈700’000
Общий объём обработанных страниц:	≈120 Gb
Отфильтрованные данные	
Общий объём файлов:	3.15 Gb
Общее число символов:	1’558’003’484
Общее число документов:	170477
Среднее число символов в документе:	9139
Средний объём документа:	19.5 Kb

Примеры запросов:

- Интересный = лучший

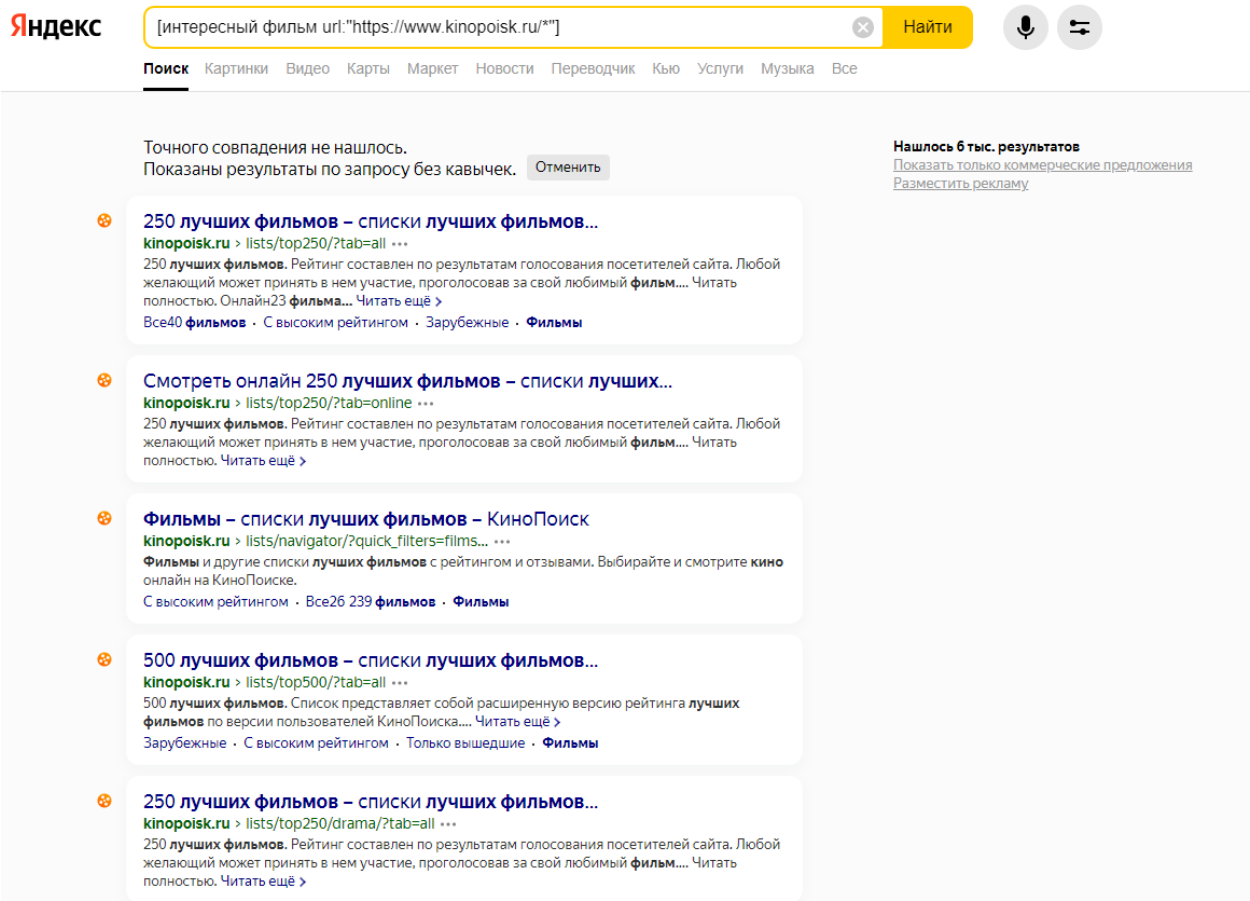

- А ещё это фамилия режиссёра

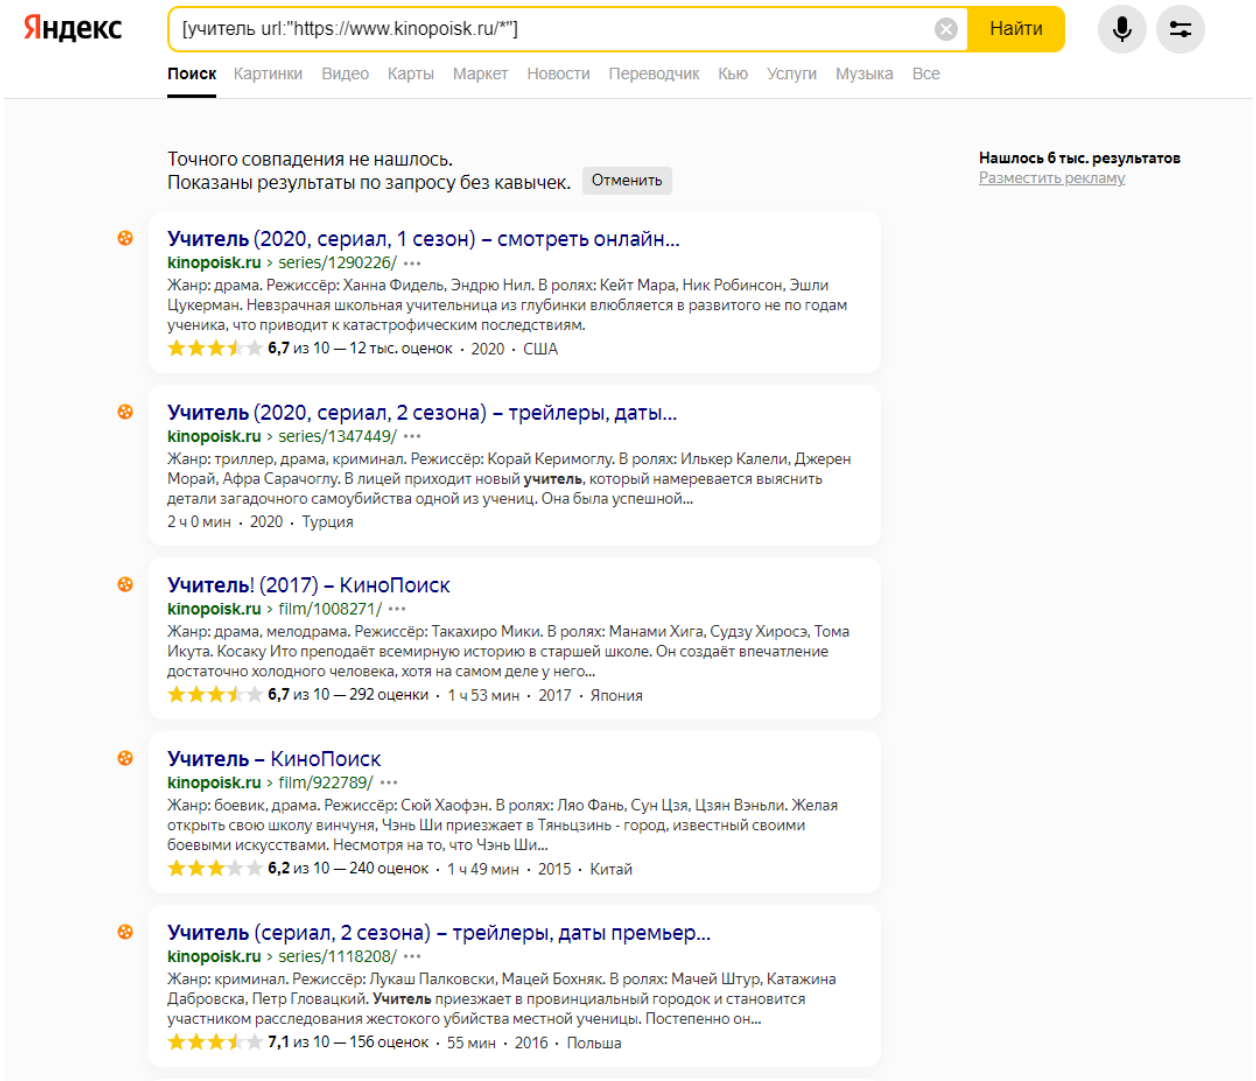

- Герой сериала

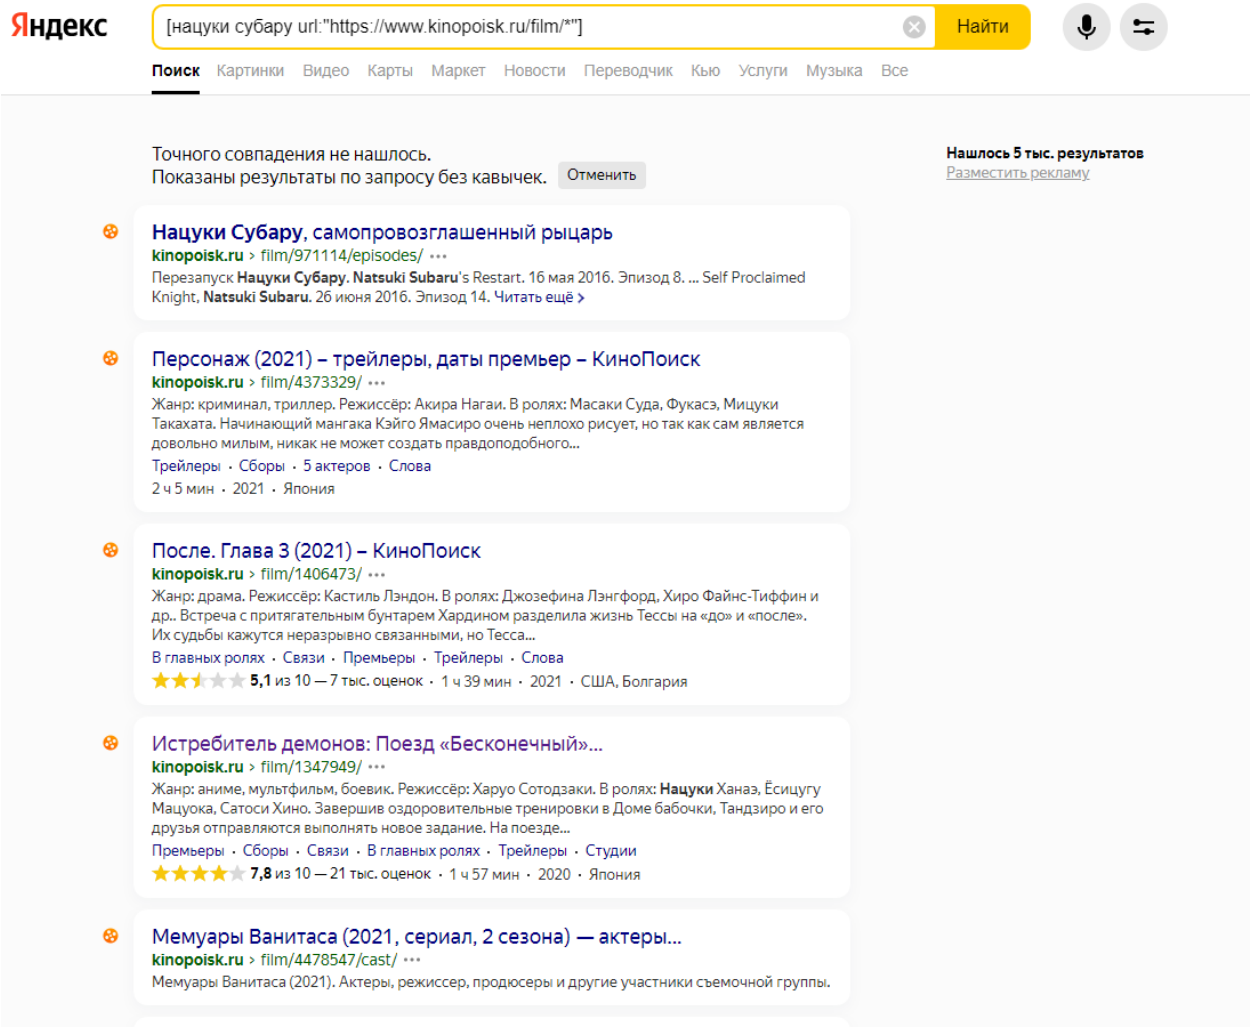

В ходе выполнения лабораторной работы я научился анализировать и скачивать *html*-страницы в автоматическом режиме, с целью извлечения нужных сведений. Это может пригодится для сбора статистики по сайту, создание агрегаторов, таких как, например, агрегатора цен на авиабилеты, поиска уязвимостей, получение корпуса документов для машинного обучения и прочее.

Список литературы

[1] Райан Митчелл *Современный скрапинг веб-сайтов с помощью Python*. 2-е межд. издание. — СПб.: Питер, 2021 — 528 с. (ISBN 978-5-4461-5)